범주형 자료의 χ^2 검정

1. 아침 식사를 거르는 학생의 비율이 학년에 따라 다른지 알아보려고, 1학년 250명과 4학년 200명을 각각 무작위로 뽑아 조사했다. 1학년은 95명, 4학년은 52명이 아침을 거른다고 답했다.

(1) 자료를 2×2 표(학년 × 아침을 거름/먹음)로 정리하고, 두 학년의 아침을 거르는 비율이 다르다고 할 수 있는지 χ^2 분포를 사용하여 유의수준 5%에서 검정하시오.

(2) 합동표본비율을 이용한 두 모비율의 Z 검정통계량을 구하고, (1)의 χ^2 값과 비교하시오.

(3) “1학년의 비율이 4학년보다 0.05를 초과하여 크다”는 주장은 χ^2 검정으로 검정할 수 없다. 그 이유를 쓰시오.

2. 학생식당의 네 코너(한식, 양식, 분식, 샐러드) 이용 비율은 작년 조사에서 35%, 30%, 20%, 15%였다. 올해 어느 날 점심 이용 학생 400명을 무작위로 골라 이용한 코너를 조사한 결과가 다음과 같다.

코너	한식	양식	분식	샐러드	합
이용 학생 수	118	142	70	70	400

(1) 올해 코너별 이용 비율이 작년과 달라졌다고 할 수 있는지 유의수준 5%에서 검정하고, 결론을 문장으로 쓰시오.

(2) 기대도수와 가장 크게 어긋난 코너는 어디인지 쓰고, 그 코너는 기대보다 많았는지 적었는지 쓰시오.

3. 직장인과 대학생이 좋아하는 운동이 다른지 알아보려고, 직장인 180명과 대학생 220명을 각각 무작위로 뽑아 가장 좋아하는 운동을 조사했다. 조사 결과와 컴퓨터로 χ^2 검정을 실행한 결과가 다음과 같다.

<조사 결과>

	헬스	러닝	구기	합
직장인	80	60	40	180
대학생	70	60	90	220

<결과 1: 각 칸의 기대도수>

	헬스	러닝	구기
직장인	67.5	54.0	58.5
대학생	82.5	66.0	71.5

<결과 2> `X-squared = 16.058, df = 2, p-value = 0.000326`

(1) 표본을 뽑은 방식에 맞는 검정의 이름을 쓰고, 귀무가설과 대립가설을 세우시오.

(2) 결과 1에서 직장인-헬스 칸의 기대도수 67.5가 어떻게 계산되었는지 쓰시오.

(3) 결과 2를 이용하여 유의수준 5%에서 결론을 내리시오.

(4) 만약 400명을 한 번에 무작위로 뽑아 직장인인지 대학생인지와 좋아하는 운동을 함께 기록했다면, 검정의 이름과 귀무가설은 어떻게 달라지는가?

추가 문제

4. 한 도서관에서 지난 학기 평일 반납 연체 150건을 무작위로 골라 요일별로 정리했다. 연체가 요일마다 고르게 일어난다고 할 수 있는지 알아보려고 한다.

요일	월	화	수	목	금	합
연체 건수	38	27	25	22	38	150

(1) 연체가 요일에 따라 고르지 않다고 할 수 있는지 유의수준 5%에서 검정하시오.

(2) 카이제곱분포표를 이용하여 이 검정의 p value가 0.1보다 큰지 작은지 판단하시오.

5. 한 대학의 학생 200명을 무작위로 뽑아 거주 형태와 아침 식사 여부를 함께 조사한 결과가 다음과 같다.

	먹음	거름	합
자취	22	38	60
기숙사	30	20	50
통학	52	38	90
합	104	96	200

(1) 알맞은 검정의 이름을 쓰고 귀무가설과 대립가설을 세우시오.

(2) 각 칸의 기대도수를 구하시오.

(3) 거주 형태와 아침 식사 여부가 관계가 있다고 할 수 있는지 유의수준 5%에서 검정하시오.

6. 다음 설명이 옳으면 O, 옳지 않으면 X를 표시하고, X인 것은 바르게 고치시오.

(1) χ^2 검정에서 대립가설이 “다르다”이면 기각역을 양쪽 꼬리에 $\alpha/2$씩 둔다.

(2) 기대도수는 귀무가설의 비율을 그대로 쓰면 되므로 0.25처럼 비율로 계산한다.

(3) 적합도 검정에서 범주가 5개이면 검정통계량의 자유도는 4이다.

(4) 2×3 분할표로 독립성 검정을 하면 자유도는 6이다.

(5) 기대도수가 5보다 작은 칸이 있어도 χ^2 분포 근사를 그대로 쓸 수 있다.

(6) 범주가 2개인 적합도 검정은 모비율 1개에 대한 양측 Z 검정과 같은 결론을 준다.

(7) 동질성 검정과 독립성 검정은 기대도수 계산 방법이 서로 다르다.

카이제곱분포표

$P(\chi^2(k) > \chi^2_\alpha(k)) = \alpha$인 값 (오른쪽 꼬리 넓이가 α)

k \ α	0.99	0.975	0.95	0.9	0.1	0.05	0.025	0.01
1	0.000	0.001	0.004	0.016	2.706	3.841	5.024	6.635
2	0.020	0.051	0.103	0.211	4.605	5.991	7.378	9.210
3	0.115	0.216	0.352	0.584	6.251	7.815	9.348	11.345
4	0.297	0.484	0.711	1.064	7.779	9.488	11.143	13.277
5	0.554	0.831	1.145	1.610	9.236	11.070	12.833	15.086
6	0.872	1.237	1.635	2.204	10.645	12.592	14.449	16.812
7	1.239	1.690	2.167	2.833	12.017	14.067	16.013	18.475
8	1.646	2.180	2.733	3.490	13.362	15.507	17.535	20.090
9	2.088	2.700	3.325	4.168	14.684	16.919	19.023	21.666
10	2.558	3.247	3.940	4.865	15.987	18.307	20.483	23.209
11	3.053	3.816	4.575	5.578	17.275	19.675	21.920	24.725
12	3.571	4.404	5.226	6.304	18.549	21.026	23.337	26.217
13	4.107	5.009	5.892	7.042	19.812	22.362	24.736	27.688
14	4.660	5.629	6.571	7.790	21.064	23.685	26.119	29.141
15	5.229	6.262	7.261	8.547	22.307	24.996	27.488	30.578
16	5.812	6.908	7.962	9.312	23.542	26.296	28.845	32.000
17	6.408	7.564	8.672	10.085	24.769	27.587	30.191	33.409
18	7.015	8.231	9.390	10.865	25.989	28.869	31.526	34.805
19	7.633	8.907	10.117	11.651	27.204	30.144	32.852	36.191
20	8.260	9.591	10.851	12.443	28.412	31.410	34.170	37.566
21	8.897	10.283	11.591	13.240	29.615	32.671	35.479	38.932
22	9.542	10.982	12.338	14.041	30.813	33.924	36.781	40.289
23	10.196	11.689	13.091	14.848	32.007	35.172	38.076	41.638
24	10.856	12.401	13.848	15.659	33.196	36.415	39.364	42.980
25	11.524	13.120	14.611	16.473	34.382	37.652	40.646	44.314
26	12.198	13.844	15.379	17.292	35.563	38.885	41.923	45.642
27	12.879	14.573	16.151	18.114	36.741	40.113	43.195	46.963
28	13.565	15.308	16.928	18.939	37.916	41.337	44.461	48.278
29	14.256	16.047	17.708	19.768	39.087	42.557	45.722	49.588
30	14.953	16.791	18.493	20.599	40.256	43.773	46.979	50.892

풀이

1.

2×2 표: 1학년 95 / 155 (합 250), 4학년 52 / 148 (합 200), 열 합 147 / 303, $n = 450$. 학년별로 따로 뽑았으니 동질성 검정.

(1) $H_0 : p_1 = p_2$ vs $H_1 : p_1 \neq p_2$. 기대도수 $250 \times \frac{147}{450} = 81.67, 168.33, 200 \times \frac{147}{450} = 65.33, 134.67$ (모두 5 이상). $\chi^2 = \frac{13.33^2}{81.67} + \frac{13.33^2}{168.33} + \frac{13.33^2}{65.33} + \frac{13.33^2}{134.67} = 2.177 + 1.056 + 2.721 + 1.320 = 7.27 > \chi^2_{0.05}(1) = 3.841$ → 기각. 아침을 거르는 비율이 학년에 따라 다르다고 할 수 있다. (p value ≈ 0.007)

(2) 합동비율 $\hat{p} = 147/450 = 0.3267$, $SE = \sqrt{0.3267 \times 0.6733 \left(\frac{1}{250} + \frac{1}{200}\right)} = 0.0445$, $z = \frac{0.38 - 0.26}{0.0445} = 2.70$. $z^2 = 7.27 = \chi^2$이고, 임계값도 $1.96^2 = 3.841$로 같아 같은 결론이다.

(3) χ^2는 차이를 제곱해서 모으므로 방향이 사라져 "다르다"(양측)만 검정할 수 있고, 귀무가설도 "같다"(차이 0)만 다룬다. 차이가 0.05를 넘는지(단측, $D \neq 0$)는 각자 비율로 구한 Z 검정으로 해야 한다.

> **포인트** 2×2 동질성 χ² = 합동비율 Z². χ²는 양측, 차이 0만.

2.

(1) H_0: 코너별 이용 비율이 0.35, 0.30, 0.20, 0.15이다 vs H_1: H_0가 아니다. 기대도수 $E = 400 \times$비율 $= 140, 120, 80, 60$. $\chi^2 = \frac{22^2}{140} + \frac{22^2}{120} + \frac{10^2}{80} + \frac{10^2}{60} = 3.457 + 4.033 + 1.250 + 1.667 = 10.41$. 자유도 $4 - 1 = 3$, $\chi^2_{0.05}(3) = 7.815$ → 기각. 올해 코너별 이용 비율은 작년과 달라졌다고 할 수 있다. (p value ≈ 0.015)

(2) 항별 기여가 가장 큰 것은 양식(4.03). 기대 120명보다 많았다(142명).

> **포인트** E는 비율이 아니라 개수. 자유도는 범주 수 − 1. 차이 크기(22)가 같아도 E가 작은 양식이 한식보다 χ²에 더 크게 기여한다.

3.

(1) 직장인, 대학생을 각각 따로 뽑았으니(행 합 180, 220이 미리 정해짐) **동질성 검정**. H_0: 좋아하는 운동의 비율이 직장인과 대학생에서 같다. H_1: H_0가 아니다(적어도 한 운동의 비율은 다르다).

(2) $\hat{E} = n_1 \times \frac{O_{\cdot 1}}{n} = 180 \times \frac{80+70}{400} = 67.5$ (행합 × 열합 / n).

(3) 자유도 $(2-1)(3-1) = 2$. p value $0.000326 < 0.05$ → 기각 (또는 $16.06 > \chi^2_{0.05}(2) = 5.991$). 좋아하는 운동의 비율이 직장인과 대학생 사이에 다르다고 할 수 있다.

(4) **독립성 검정**. H_0: 직업(직장인/대학생)과 좋아하는 운동은 독립이다. H_1: 독립이 아니다. 기대도수, χ^2, 자유도 계산은 같다.

> **포인트** 계산은 같고, 표본을 뽑은 방식이 검정 이름과 가설을 정한다. 시험에서는 검정 이름 + 가설 + 결론 문장이 점수.

추가 문제

4.

(1) H_0: 요일별 연체 비율이 모두 1/5이다 vs H_1: H_0가 아니다. $E = 150 \times \frac{1}{5} = 30$. $\chi^2 = \frac{8^2+3^2+5^2+8^2+8^2}{30} = \frac{226}{30} = 7.53 < \chi^2_{0.05}(4) = 9.488$ → 기각 못 함. 연체가 요일에 따라 고르지 않다고 할 수 없다.

(2) $7.53 < \chi^2_{0.1}(4) = 7.779$이므로 p value는 0.1보다 크다. (실제 ≈ 0.110)

> **포인트** "고르게" = 모든 범주의 비율이 같다는 적합도. 기각 못 함은 "고르다"의 증명이 아니라 증거가 부족하다는 뜻.

5.

(1) 200명을 한 번에 뽑아 두 특성을 함께 기록했으니 **독립성 검정**. H_0: 거주 형태와 아침 식사 여부는 독립이다. H_1: 독립이 아니다.

(2) $\hat{E}_{ij} = \frac{\text{행합} \times \text{열합}}{n}$: 자취 $\frac{60 \times 104}{200} = 31.2, 28.8$ / 기숙사 $26.0, 24.0$ / 통학 $46.8, 43.2$.

(3) $\chi^2 = \frac{9.2^2}{31.2} + \frac{9.2^2}{28.8} + \frac{4^2}{26} + \frac{4^2}{24} + \frac{5.2^2}{46.8} + \frac{5.2^2}{43.2} = 2.713 + 2.939 + 0.615 + 0.667 + 0.578 + 0.626 = 8.14$. 자유도 $(3-1)(2-1) = 2$, $\chi^2_{0.05}(2) = 5.991 \rightarrow$ 기각. 거주 형태와 아침 식사 여부는 관계가 있다고 할 수 있다(자취생이 아침을 더 많이 거름). (p value ≈ 0.017)

> **포인트** 열이 2개인 표에서는 행마다 |O − E|가 같다. 관계가 있다는 것은 인과가 아니라 같이 움직인다는 뜻.

6.

(1) X: χ^2 검정은 항상 오른쪽 꼬리만. (2) X: 기대도수는 $n \times$비율로 구한 개수. (3) O: $c - 1 = 4$. (4) X: $(2-1)(3-1) = 2$. (5) X: 모든 칸의 기대도수가 5 이상이어야 근사가 맞다. (6) O: $\chi^2 = Z^2$. (7) X: 둘 다 행합 × 열합 / n으로 같다. 다른 것은 표본을 뽑는 방식과 가설.

> **포인트** (1)은 χ^2가 차이를 제곱해서 모으기 때문에 “다르다”여도 큰 쪽만 귀무가설에 불리함.