Ch 1 - 자료의 생성

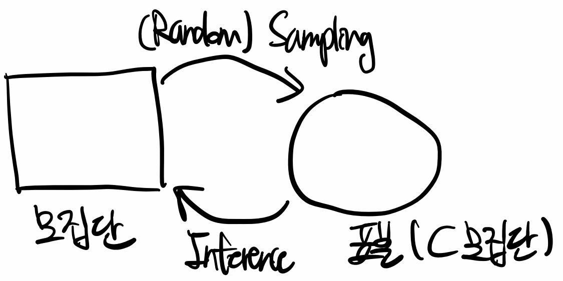

· 추출단위 : 전체 구성하는 각 개체
· 특성값 : 추출단위의 특성 나타내는 값

- 모집단
  - 유한 모집단
  - 무한 모집단

· 조사 vs · 실험

- 조사
  - 전수조사
  - 표본조사 → 유의사항
    - ① bias 방지 → 모집단 list 필요
    - ② 무응답 방지 → 응답 그룹 vs 무응답 그룹 비교 분석 필요
    - ③ 결측값 처리 → 가중치 조정

"표본이 모집단을 잘 대표할 수 있어야 함"

↳ SRS (Simple Random Sampling) : 모든 부분집합이 표본으로 선택될 확률 동일

"꼭고주"

⇒ 통에 있는 n개의 개별들

↳ (복원 … 독립 O
 비복원 … 독립 X

· 자료

- 수치형
  - 연속형
  - 이산형
- * vs 숫자냐 아니냐!
- 범주형
  - 명목형
  - 서열형

Ch 2 – 모집단과 표본

- **분포** : 특성값이 흩어져 있는 상태를 $\Sigma = 1$인 양수로 나타낸 것.
  ⇒ 결국, 전체를 다 알고자 하는 것!

→ 범주형 + 이산형 자료 : 상대도수 (≒ 확률)

→ 연속형 자료 : $\underbrace{\text{밀도곡선}}$ (∵ 상대도수로 하면 계급 나누는 간격 등에 의해 다양한 형태가 되어 일관성↓ ⇒ '곡선')
  └ 식 찾기가 목표

- **모수** : 모집단의 특징 나타내는 대푯값
(parameter)
  - 위치 : 평균, 백분위수, ...
  - 산포 : 분산, 표준편차, ...

– 모평균 : 분포의 균형점 ... 중심위치!

→ 유한모집단 : $\mu = \frac{1}{N}(c_1 + \cdots + c_N) = \frac{1}{N}\sum_{i=1}^{N} c_i = \frac{1}{N}\sum_{i=1}^{K} c_i^* \cdot f_i = \boxed{\sum_{i=1}^{K} c_i^* \cdot \left(\frac{f_i}{N}\right)}$

; c_i^* 서로 다른 특성값
$\frac{f_i}{N}$ 상대도수
f_i 도수

→ 무한모집단 : $\boxed{\mu = \begin{cases} \sum x p(x) & (\text{이산}) \\ \int_{-\infty}^{\infty} x \underbrace{p(x)}_{\text{밀도곡선}} dx & (\text{연속}) \end{cases}}$

– 제 p 백분위수

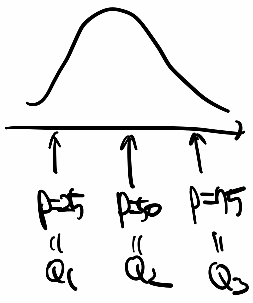

⇒ Q_2 (모중앙값) : 중심위치! (& 밀도곡선 넓이 이등분 (연속인 때) & $\mu = Q_2$ (좌우대칭일 때))

→ 절대평균편차 (MAD, Mean Absolute Deviation) : $|c_i - Q_2|$의 평균 ⇒ $\frac{1}{N}\sum_{i=1}^{N}|c_i - Q_2|$

→ 사분위수범위 (IQR, Inter-Quartile Range) : $Q_3 - Q_1$ ⇐ outlier 영향 거의 X

- 모분산 : (편차)^{2}의 평균 … 변동의 척도!

→ 유한모집단 : $\boxed{\sigma^2 = \sum_{i=1}^{k} (c_i^* - \mu)^2 \left(\frac{f_i}{N}\right)}$

→ 무한모집단 : $\boxed{\sigma^2 = \begin{cases} \sum (x-\mu)^2 p(x) & (이산) \\ \int_{-\infty}^{\infty} (x-\mu)^2 p(x)\,dx & (연속) \end{cases}}$

- 기술통계학 : 자료의 특성 정리·요약 방법 다루는 분야

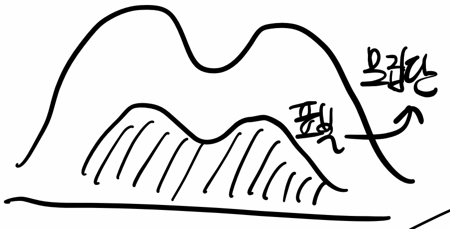

시각적 요약 … 왜곡 주의

수치적 요약

→ 범주형 자료 : 도수분포표, 막대그래프, …

→ 연속형 자료 : 도수분포표, 히스토그램, 줄기-잎 그림, 상자그림, …

계급 설정에 따라 왜곡 가능

보완 (but, 대량 자료에서 사용 어려움)

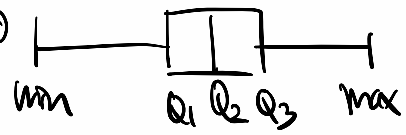

: fence = 1.5×IQR

*히스토그램

- 왜도

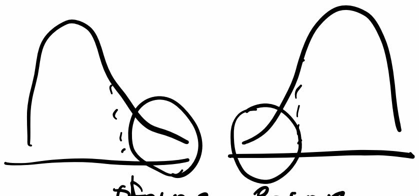

양의왜도 Right ⇓ 중<평

음의왜도 Left ⇓ 평<중

· 모집단과 표본

- 통계량 ← 계산의 대상
- 추정량

} $\bar{x}$는 통계량이고, μ의 추정량.

· 표본평균 : $\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i$ … $\bar{x} = \hat{\mu}$

⊕ $\widehat{IQR} = \hat{Q}_3 - \hat{Q}_1$

· 표본분산 : $s^2 = \frac{1}{\boxed{n-1}}\sum_{i=1}^{n}(x_i - \bar{x})^2$ … $s^2 = \hat{\sigma}^2$

← $\frac{1}{n-1}$은 $\bar{x}$로 추정할 때!!! (μ 알면 자유도 -1 안 됨)

① 표본분산은 모분산을 과소추정
② 표본분산의 자유도

→ s^2 간편식 : $s^2 = \frac{1}{n-1}\sum_{i=1}^{n}(x_i^2 - n\bar{x}^2)$

(cf) $\sigma^2 = E(X^2) - \{E(X)\}^2$

· 표본표준편차 : $s = \sqrt{\frac{1}{n-1}\sum_{i=1}^{n}(x_i - \bar{x})^2}$

- 변동계수 (CV, Coefficient of Variation) : $CV = \frac{s}{\bar{x}} \times 100$ (%)

Ch 3 - 확률과 확률분포

- 확률
  - → 고전적 방법 : $P(A) = \frac{m}{N}$
  - → 경험적 방법 : 상대도수의 극한
  - ⇒ 공리적 정의
    - ① 표본공간 S에서 임의의 사건 A에 대해 $0 \le P(A) \le 1$
    - ② $P(S) = 1$
    - ③ 서로 배반인 사건 $A_1, A_2, \cdots$ 에 대해 $P(A_1 \cup A_2 \cup \cdots) = P(A_1) + P(A_2) + \cdots$
  - ⇒ $P(A)$

- 조건부 확률 : $P(B|A) = \frac{P(A \cap B)}{P(A)}$ "특정 사건 하에서"
  → 표본공간의 축소
  - 곱셈법칙 : $P(A \cap B) = P(A|B)P(B) = P(B|A)P(A)$
  - ★ 독립사건 : $\begin{cases} P(A|B) = P(A) \\ P(B|A) = P(B) \\ P(A \cap B) = P(A)P(B) \end{cases}$ ⇔ A와 B는 서로 독립

- 확률변수 : $X : S \to \mathbb{R}$ 함수

↓

- 확률분포 : 확률변수가 취할 수 있는 값들에 확률이 대응되어 있는 것
  - 확률분포함수 : 확률변수의 확률분포를 함수로 나타낸 것
    - → 이산형 ↔ 확률질량함수 : $p(x) = \begin{cases} f(X = x_i), & (i = 1, 2, \cdots, n) \\ 0, & o.w. \end{cases}$
    - → 연속형 ↔ 확률밀도함수 : $P(a \le X \le b) = \int_a^b f(x)\,dx$
      - └ 높이 의미X, 면적 의미O
        등호 의미X

⊕ 누적확률함수 $F(x) = P(X \le x) = \sum_{X \le x} p(x)$

① 누적분포함수 $F(x) = P(X \le x) = \int_{-\infty}^{x} f(x)\,dx$

- 확률변수

– 기댓값

$$: \mu = E(X) = \begin{cases} \sum x p(x) \\ \int_{-\infty}^{\infty} x p(x) dx \end{cases} \quad \cdots \quad E(g(X)) = \begin{cases} \sum g(x) p(x) \\ \int_{-\infty}^{\infty} g(x) p(x) dx \end{cases}$$

$$\Rightarrow E(aX+b) = aE(X)+b$$

– 분산

$$: \sigma^2 = V(X) = E((X-\mu)^2) = \begin{cases} \sum (x-\mu)^2 p(x) \\ \int_{-\infty}^{\infty} (x-\mu)^2 p(x) dx \end{cases}$$

$$\Leftarrow V(X) = E(X^2) - \{E(X)\}^2$$

$$\Rightarrow V(aX+b) = a^2 V(X), \quad V(X) \geq 0$$

– 표준편차

$$: \sigma = sd(X) = \sqrt{V(X)} = \sqrt{E((X-\mu)^2)}$$

– 표준화

$$Z = \frac{X - E(X)}{sd(X)} \dashrightarrow E(Z) = 0, \; V(Z) = 1$$

- 결합분포 : 두 확률변수가 취할 수 있는 모든 순서쌍에 대한 분포
(결합확률분포)

<--> 주변확률분포 : 혼자만의 분포
(주변분포)

$$\hookrightarrow \begin{cases} p_1(x) = \sum_{\text{all } y} p(x,y), \; p_2(y) = \sum_{\text{all } x} p(x,y) \\ f_1(x) = \int_{-\infty}^{\infty} f(x,y) dy, \\ f_2(y) = \int_{-\infty}^{\infty} f(x,y) dx \end{cases}$$

⇓

관심있는 변수가 아닌 변수의 영향 제거!
(by Σ or $\int$)

→ 이산형 : 결합확률질량함수 $\quad p(x,y) = P(X=x, Y=y)$

→ 연속형 : 결합확률밀도함수 $\quad P(a \leq X \leq b, c \leq Y \leq d) = \int_a^b \int_c^d f(x,y) dy dx$

*두 확률변수가 서로 독립 $\Leftrightarrow \begin{cases} p(x,y) = p_1(x) p_2(y) \\ f(x,y) = f_1(x) f_2(y) \end{cases}$

- 공분산 : 두 변수가 $\underbrace{\text{어느 방향으로}}_{\text{부호}}$ $\underbrace{\text{얼마나}}_{\text{크기}}$ 변동하는지 나타냄

표준화

$$Cov(X,Y) := E\left((X-\mu_X)(Y-\mu_Y)\right) \longrightarrow \begin{cases} >0 & : \text{양의 선형관계} \\ <0 & : \text{음의 선형관계} \\ =0 & : \text{선형관계X (관계 없는 것은 X ⋯ 오흡)} \end{cases}$$

→ Cov 간편식: $Cov(X,Y) = E(XY) - E(X)E(Y)$

$\Rightarrow Cov(aX+b, cY+d)$
$= ac\,Cov(X,Y)$

- 상관계수

$$\rho = Corr(X,Y) := \frac{Cov(X,Y)}{\sqrt{V(X)}\sqrt{V(Y)}} = E\left(\left(\frac{X-\mu_X}{\sigma_X}\right)\left(\frac{Y-\mu_Y}{\sigma_Y}\right)\right)$$

$\Rightarrow Corr(aX+b, cY+d)$

$$= \begin{cases} Corr(X,Y) & , ac>0 \\ -Corr(X,Y) & , ac<0 \end{cases}$$

- $-1 \le \rho \le 1$

$\lvert\rho\rvert$:	~0.3	0.3~0.6	0.6~0.8	0.8~1
	약함	보통	강함	매우 강함

$$\star\ V(X \pm Y) = V(X) + V(Y) \boxed{\pm 2Cov(X,Y)}$$

☆ ← 독립이면 Cov=0 이므로 사라지는 항
(but, 역은 성립 X)
Cov=0 ⇏ 독립 (∵ Cov=0은 선형관계 없다는 것만 보여줌!)

$$- \ Corr(X, aX+b) = \frac{a}{|a|} = \begin{cases} 1 & , a>0 \\ -1 & , a<0 \end{cases}$$

(기울기 ≠ 선형성)

$\boxed{\text{Ch 4}}$ - 표본분포

- 베르누이 분포 : 시행 결과가 이분법적 s or f … 1 or 0
  - $P(s)=p$. $P(f)=1-p$
  - 베르누이 확률변수 : $S=\{s,f\}$ 에서 $X(s)=1$, $X(f)=0$ 인 확률변수
    - ↳ 베르누이 분포 $X \sim Ber.(p)$
  - 확률질량함수 : $p(x)=p^x(1-p)^{1-x}$, $x=0,1$
  - 기대값 & 분산 : $\boxed{E(X)=p}$, $\boxed{V(X)=p(1-p)}$

- 정규분포
  - $X \sim N(\mu, \sigma^2)$
  - 평균 중심 대칭, |대칭점 - 변곡점| = 표준편차
    - ⇒ μ, σ로 설명

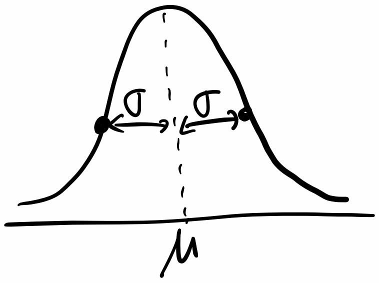

  - $(\mu-\sigma, \mu+\sigma)$: 68%
  - $(\mu-2\sigma, \mu+2\sigma)$: 95%
  - $(\mu-3\sigma, \mu+3\sigma)$: 99.7%

  - $X \sim N(\mu, \sigma^2) \rightarrow aX+b \sim \boxed{N}(a\mu+b, a^2\sigma^2)$
  - $X_1 \sim N(\mu_1, \sigma_1^2)$ & $X_2 \sim N(\mu_2, \sigma_2^2) \rightarrow a_1X_1+a_2X_2 \sim \boxed{N}(a_1\mu_1+a_2\mu_2, a_1^2\sigma_1^2+a_2^2\sigma_2^2)$
    & X_1와 X_2는 ind.
    - ⇒ 선형 변환 or 선형 결합 해도 여전히 정규분포

  - 표준정규분포 $Z=\frac{X-\mu}{\sigma} \sim N(0,1)$
    - ↳ $100(1-\alpha)$ 백분위수 : $P(Z \ge z_\alpha)=\alpha$
      오른쪽 꼬리 기준

$z_{0.025}=1.96$
$z_{0.05}=1.645$
} 임계값으로 자주 활용 (χ^2, t, F과 반대)

표본

- 표본분포 (표집분포) : 통계량의 확률분포 ← ① 모집단의 분포 (못 건듦) ②* 표본의 추출방법 에 의해 결정

- 랜덤표본

→ 복원추출 (SRSWR) : $P(X_2=1 \mid X_1=1) = P(X_2=1)$ ⇒ ind.
$P(X_1=1) = P(X_2=1)$ ⇒ identical.

→ 비복원추출 (SRSWOR) : $P(X_2=1 \mid X_1=1) \neq P(X_2=1)$ ⇒ dep. → n에 비해 N 충분히 크면 $\neq \to \approx$ $\left(\frac{n}{N} \to 0\right)$
$P(X_1=1) = P(X_2=1)$ ⇒ identical.

⇒ 랜덤표본
- 유한모집단 : SRSWOR (단순랜덤비복원 추출)로 뽑은 표본 : identical & dep. → N ⇑ → ind.
- 무한모집단 : ① $X_1, \dots, X_n$은 모집단 분포와 동일 & ② $X_1, \dots, X_n$은 서로 독립 : identical & ind.

- i.i.d. (Independently and Identically Distributed)
⟺ ind. & identical

→ 무한모집단의 랜덤표본 or N이 충분히 큰 유한모집단의 랜덤표본 (or 복원추출된 유한모집단의 랜덤표본) : i.i.d.
(by definition) $\left(\frac{n}{N} \to 0\right)$ (근사적으로)
$\left(\frac{n}{N} \le 0.05\right)$

- 표본 분포

→ 이산형 모집단

- 유한모집단 ($X = \sum X_i$) : $\boxed{\text{초기하분포}}$
  - ↳ $(X_1, \dots, X_n) \sim Ber.\left(\frac{D}{N}\right)$ 에서 $\sum X_i$ (X=1의 개수) ; identical & dep.
  - ⇒ $X \sim H(N, D, n)$
  - ⇒ $\boxed{p(x) = \frac{\binom{D}{x}\binom{N-D}{n-x}}{\binom{N}{n}}}$, $x = 0, 1, \dots, n$

$$\left.\right\} \quad E(X) = np \quad \left(p = \frac{D}{N}\right), \qquad V(X) = np(1-p)\frac{N-n}{N-1}$$

FPC (Finite Population Corrector, (<1) 유한모집단 수정계수) … 분산↓ … 안정적

- 무한모집단 ($X = \sum X_i$) : $\boxed{\text{이항분포}}$ ← (i.i.d. Ber.) 베르누이 시행 독립적으로 n번 반복 시의 성공횟수 $X \sim B(n, p)$
  - ↳ $(X_1, \dots, X_n) \sim Ber.(p)$ 에서 $\sum X_i$ (X=1의 개수) ; identical & ind.
  - ⇒ $X \sim B(n, p)$
  - ⇒ $\boxed{p(x) = \binom{n}{x} p^x (1-p)^{n-x}}$, $x = 0, 1, \dots, n$

$$\left.\right\} \quad E(X) = np, \qquad V(X) = np(1-p)$$

↳ $P(a \le X \le b) = \sum_{k=a}^{b} p(k)$ 계산할 때 :
- ① n이 작음 : 직접 계산 or 이항분포표
- ② n이 매우 큼 : 계산 X → 정규근사 (But, 연속성 수정 필요) 반드시!!!
  (np≥5, n(1-p)≥5)

↳ $(X_1, \dots, X_n) \to \sum X_i \sim B(n, p)$
$\overset{CLT}{\Rightarrow} \sum X_i \;\dot\sim\; N(np, np(1-p))$
$\left(\because X = \sum X_i,\ \underset{\overset{\|}{\hat{p}}}{\bar{X}} = \frac{X}{n} \;\dot\sim\; N\left(p, \frac{p(1-p)}{n}\right)\right)$

→ 연속형 모집단 (무한모집단)
- 정규분포 $\sim N$
  ($\bar{X}$)
- 비정규분포 $\dot\sim N$
  ($\bar{X}$)

— 표본평균 $\bar{X} = \frac{1}{n}(X_1 + \dots + X_n)$

⇒ 모평균이 μ, 모분산이 σ^2, 표본의 크기가 n (무한모집단일 때) : $E(\bar{X}) = \mu$, $V(\bar{X}) = \frac{\sigma^2}{n}$, $sd(\bar{X}) = \frac{\sigma}{\sqrt{n}}$

↑ 유한모집단이면 $\left(\times \left[\frac{N-n}{N-1}\right]\right)$

- 표준오차 : 통계량의 표준편차 ; 통계량의 '정확성'과 관련, 의미상 산포와 분리하기 위함
(S.E. : Standard Error) ⇒ 표본 분포의 변동성

⇒ 표준오차 : 통계량의 흩어짐의 정도
표준편차 : 자료의 흩어짐의 정도

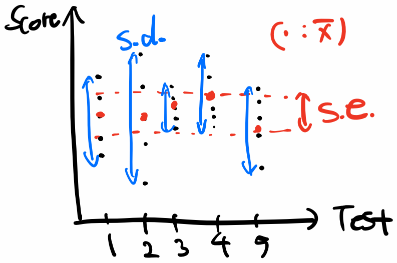

* 모집단이 $N(\mu, \sigma^2) \rightarrow (X_1, \dots, X_n) \overset{i.i.d.}{\sim} N(\mu, \sigma^2) \Rightarrow \bar{X} \sim N(\mu, \frac{\sigma^2}{n})$

* 임의의 모집단이 $(\mu, \sigma^2) \longrightarrow \bar{X} \dot{\sim} N(\mu, \frac{\sigma^2}{n}) \Leftrightarrow \frac{\bar{X}-\mu}{\sigma/\sqrt{n}} \dot{\sim} N(0,1)$ } CLT (Central Limit Theorem) : 중심극한정리

모집단이 정규분포 아니어도

*n이 충분히 큼 (경험상 $n \geq 30$)

- 연속성 수정 : 이산형 분포 → 연속형 분포 근사하여 발생하는 오차 보정
  → 최소단위의 절반 기준

eg) $P(7 \leq X^B \leq 10) \approx P(6.5 \leq X^N \leq 10.5)$
$P(7 < X^B < 10) \approx P(7.5 < X^N < 9.5)$

- χ^2 분포
  : $Z_1, \dots, Z_k$가 $N(0,1)$의 랜덤표본 → $Z_1^2 + \dots + Z_n^2 \sim \chi^2(k)$ 자유도
  $((Z_1, \dots, Z_k) \overset{i.i.d.}{\sim} N(0,1))$

- $V_1 \sim \chi^2(k_1)$, $V_2 \sim \chi^2(k_2)$ & V_1과 V_2는 ind. $\Rightarrow V_1 + V_2 \sim \chi^2(k_1 + k_2)$

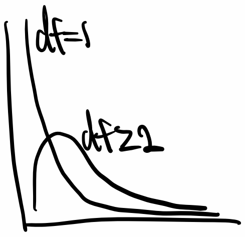

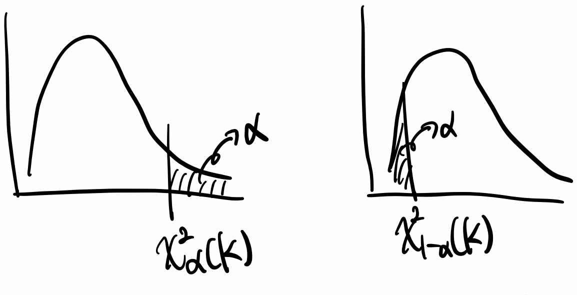

확률로 임계값 찾음(표에서)

- $N(\mu, \sigma^2)$에서의 랜덤표본 $X_1, \dots, X_n$의 표본분산 : $S^2 = \frac{1}{n-1} \sum_{k=1}^{n} (X_i - \bar{X})^2$
  $\Rightarrow \boxed{\frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)}$

- t 분포

: $Z \sim N(0,1)$과 $V \sim \chi^2(k)$가 독립 → $T = \dfrac{Z}{\sqrt{V/k}} \sim t(k)$

→ 표준정규분포처럼 0을 중심으로 좌우대칭. But, 꼬리가 두꺼움

→ k 커질수록 표준정규분포와 유사 … $k \geq 30$ 이면 표준정규분포로 대체 가능

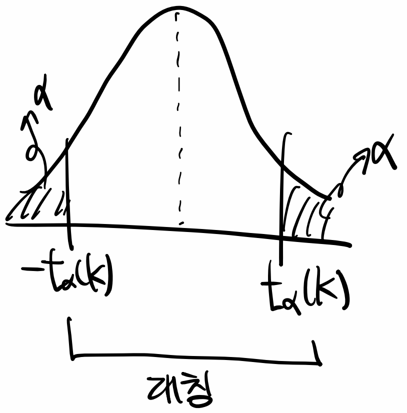

확률로 임계값 찾음

- 스튜던트화된 표본평균의 분포

: $N(\mu, \sigma^2)$에서 추출된 랜덤표본 $X_1, \dots, X_n$ → $\boxed{\dfrac{\bar{X}-\mu}{S/\sqrt{n}} \sim t(n-1)}$ $(\approx N(0,1))$ $n-1 \geq 30$

$\sigma \neq \hat{\sigma}$

- F 분포

: $V_1 \sim \chi^2(k_1)$과 $V_2 \sim \chi^2(k_2)$가 독립 → $F = \dfrac{V_1/k_1}{V_2/k_2} \sim F(k_1, k_2)$

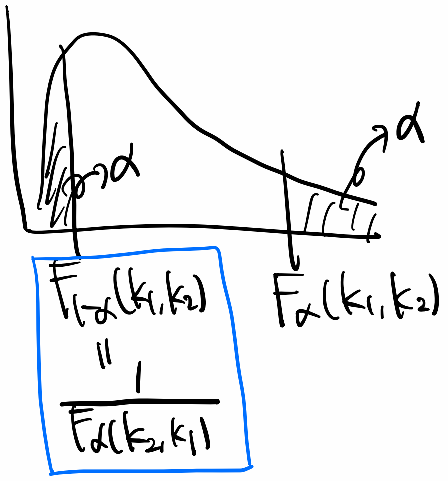

확률로 임계값 찾음

- $F \sim F(k_1, k_2)$일 때 $\dfrac{1}{F} \sim F(k_2, k_1)$

→ $\left\{ \begin{array}{l} N(\mu_1, \sigma_1^2)\text{에서의 랜덤표본 } X_1, \dots, X_{n_1} \\ \& \\ N(\mu_2, \sigma_2^2)\text{에서의 랜덤표본 } Y_1, \dots, Y_{n_2} \end{array} \right\}$ → $\boxed{\dfrac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F(n_1-1, n_2-1)}$

- t 분포와 F 분포

  : $T \sim t(k) \Rightarrow T^2 \sim F(1,k)$

- Q-Q plot (Quantile-Quantile plot, 정규분포 분위수 대조도) → 실제와 이론의 확률밀도함수를 등분하여 분위수(임계값) 비교

  : (정규분포의 이론적 분위수, 자료 분포의 실제 분위수)를 plot으로 나타낸 것

  ⇒ 점들이 직선에 밀집할 경우 모집단의 정규분포 가정을 만족

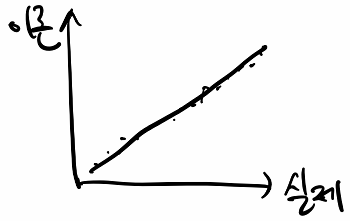

Ch 5 - 통계적 추론

모수 (θ) : $\mu, \sigma^2, \cdots$

추정량 ($\hat{\theta}$) : $\hat{\mu} = \bar{X}$, $\hat{\sigma}^2 = S^2$

추정치 : 추정량의 관측값 : $\bar{x}, s^2, \cdots$

⇒ 추정 : N개 원소 모집단에서 n개 표본 추출 후, 이를 토대로 모수의 값을 추측

→ 모집단의 특성치에 대한 추측값을 제공하고, 그 오차한계를 제시

- 점추정 : 단일 추정치로 모수 추정 "값"

  - 표집오차 : 표본만 관측해서 생기는 오차

$$= \hat{\theta} - \theta = \underbrace{[\hat{\theta} - E(\hat{\theta})]}_{\text{변동}\downarrow\ ②} + \underbrace{[E(\hat{\theta}) - \theta]}_{\text{편향}\downarrow\ ①}$$

단점 보완… '범위 정보'에 대한 정보도 제공

〈바람직한 성질〉

① 불편성 (비편향성) … $E(\hat{\theta}) = \theta$ 이면 $\hat{\theta}$는 θ의 불편(비편향)추정량

↳ 표본 분포를 구해보면, 추정량 값들이 "평균적으로" 모수와 일치

$E(\bar{X}) = \mu$, $E(S^2) = \sigma^2$

$\frac{1}{n-1}\sum (x_i - \bar{x})^2$ … $\frac{1}{n}$ 이면 등호 성립 X

만족

② 효율성 … 비편향량 중에서 분산 가장 작은 것!

(변동↓ ⋯> 분산↓)

→ 최소분산 불편추정량 (MVUE) : 불편추정량 중 분산 가장 작은 추정량

- 구간추정 : 점추정량 값에 표집오차 크기를 함께 반영하여 구간으로 나타낸 것 "구간"

  - 신뢰구간 : 구간추정으로 얻어지는 구간 ← 신뢰수준 & 구간의 크기에 따라 결정됨

신뢰수준 ($1-\alpha$) : 여러 번 구한 신뢰구간 중 모수를 포함하는 신뢰구간의 비율 … 높을수록 바람직함

구간의 크기 : 신뢰구간의 폭 … 작을수록 바람직함

서로 상충관계

⇒ 신뢰수준($1-\alpha$) 고정 후 구간의 길이 최소화

⇔ $P(a<\mu<b) = 1-\alpha$ 만족하는 수많은 (a,b) 중 가장 길이 짧은 것 선택

↳ 좌우대칭

$$\Rightarrow \mu \in \left(\bar{X} - Z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}},\ \bar{X} + Z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}\right) : \text{신뢰구간}$$

$d = Z_{\frac{\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}$: 오차한계 (margin of error)

→ 신뢰수준

① 모수가 신뢰구간에 포함될 확률 X vs 신뢰구간이 모수를 포함할 확률 O

⇒ ∵ 모수는 이미 정해진 값 & 신뢰구간은 표본에 따라 달라지는 것

② 이미 구한 신뢰구간이 모수를 포함할 확률? X

⇒ ∵ 신뢰구간 구했으면 모수 포함 여부는 이미 결정됨, but 모르는 것일 뿐

→ 결국, '신뢰수준'은 방법론에 대한 평가의 척도 & 이미 관측한 관측치에 대한 평가는 의미가 없음

- 표본 크기의 결정

↳ $d = z_{\frac{\alpha}{2}} \frac{\sigma}{\sqrt{n}} \Rightarrow n \geq \left(z_{\frac{\alpha}{2}} \frac{\sigma}{d} \right)^2$ … 오차범위를 d 이하로 줄이기 위한 표본의 크기

· 가설검정 : 모수에 대한 특정 주장 받아들일지 여부를 데이터로 판단

간접적 추론방법

↕

추정 : 데이터로 모수의 추측값 구함

직접적 추론방법

귀무가설(H_0) : 기존 가설

대립가설(H_1) : 대안 가설

→ 유의성 검정 : 귀무가설에 대한 반증의 강도를 평가하는 과정

↳ 귀무가설에 반대 & 대립가설을 지지하는 증거 찾는 것이 목적

⇒ 귀무가설 옳다는 전제 하에 일어나기 매우 어려운 현상 관측을 통해 새로운 가설 제시

① 귀무가설 기각

② 대립가설 제시

⇒ 가설 검정의 단계

① 가설 설정 $\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu > \mu_0 \end{cases}$ or $\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu < \mu_0 \end{cases}$ or $\begin{cases} H_0 : \mu = \mu_0 \\ H_1 : \mu \neq \mu_0 \end{cases}$

단측가설 · 양측가설

↓

② 유의수준 : $P(H_0 \text{ reject} \mid H_0 \text{ true}) = \alpha$; 제 1종 오류

$P(H_0 \text{ accept} \mid H_1 \text{ true}) = \beta$; 제 2종 오류

검정 \ 실제	H_0	H_1
H_0	$1-\alpha$	β
H_1	α	$1-\beta$

신뢰수준

검정력

⇒ α, β는 상충관계 ⇒ α 고정 후 β 최소화 (⇔ $(1-\beta)$ 최대화)

↓

③ 표본 추출 → 검정통계량 계산

↳ 보통 모수의 점추정량 표준화한 것

⇒ H_0 하에 관측된 통계량이 관측될 가능성 판단 … ⇒ 점추정량의 분포 필요!

↳ N : 모집단 정규 or CLT …

↓

④-1 기각역 검토

: 귀무가설을 기각하게 되는 영역 … α

⇐ 유의수준 달라지면 새로 기각역 설정 필요 & 기각의 강도 모름

or

④-2 p-value 검토

: H_0 하에 검정통계량이 치우칠 확률 (유의확률) … 작을수록 H_0에 대한 반증 강함

↳ p-value 작다 ⇔ H_0 하에서 더 강력하게 H_0 기각할 데이터가 나올 확률이 적다

⇔ 충분히 H_0를 기각할 수 있다

단측검정 vs 양측검정 구분!

기각역 : α & $\frac{\alpha}{2}$ 구분

p-value : 한쪽 넓이 ×2

↳

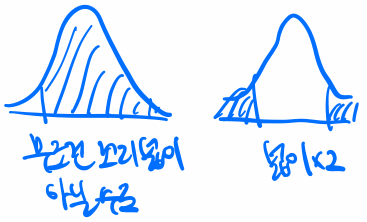

오른쪽 꼬리넓이 아님 주의

넓이×2

⇒ n값 커지면 $\bar{X}$의 S.E. 줄어듦 → p-value 낮음 가능 … 의미없는 대립가설 지양 필요

- 모평균에 대한 추론

  - 모분산을 알 때 (현실적으로는 X) : z-test

    ① 가설 설정

    ② 유의수준

    ③ 검정통계량 $\left[\begin{array}{l}\text{모집단 정규분포} \\ n \Uparrow : \text{CLT}\end{array}\right] \rightarrow \frac{\bar{X}-\mu_0}{\sigma/\sqrt{n}} \begin{array}{l}\sim N(0,1) \\ \dot{\sim} N(0,1)\end{array}$

    ④ 기각역 or p-value

    ⑤ 의미 기술

(- 신뢰구간 이용 : 양측검정 → 신뢰구간이 귀무가설의 모수를 포함하지 않으면 귀무가설 기각 가능
(기각역과 완전 동일, but, p-value 계산은 따로 해야함))

- 1종오류&2종오류 : α고정 후 β최소화 …

  n 커지면 분산 작아져
  β 최소화됨

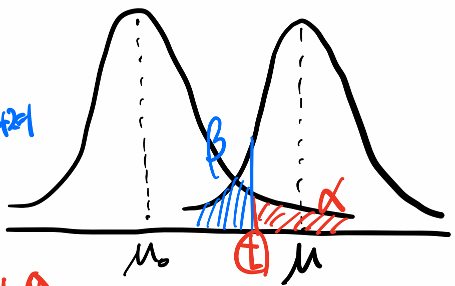

∴ α고정 후 표본 크기 ⇑

→ β or (1-β) 구하기 : ① t값(임계값) 구함 ② 표준화

$ⓣ = \mu_0 \pm z_\alpha \frac{\sigma}{\sqrt{n}}$ (or $z_{\frac{\alpha}{2}}$)

$P\left(Z \le \frac{t-\mu}{\sigma/\sqrt{n}}\right) = 1-\beta$ (or $\ge$)

Ch 6

- 모분산을 모를 때 (현실적) : t-test

  ㄴ 이 때도 $\bar{X} \sim N(\mu, \frac{\sigma^2}{n})$ 인 것은 동일
  단지 σ를 모르는 것 뿐임

$$\Rightarrow \boxed{\frac{\bar{X}-\mu}{S/\sqrt{n}} \sim t(n-1)}$$

★ 표본평균이 정규분포임을 꼭 확인해야 함

(① 모집단 정규분포
② $n \Uparrow$: CLT) ⇒ $\bar{X} \sim N$

ⓣ $n \Uparrow$: t분포 → 표준정규분포 근사 가능
($n \ge 30$
$df \ge 30$)
robust ; χ^2 영향 ⇓

→ 모평균의 신뢰구간 : $\left(\bar{x} - t_{\frac{\alpha}{2}}(n-1)\frac{s}{\sqrt{n}}, \bar{x} + t_{\frac{\alpha}{2}}(n-1)\frac{s}{\sqrt{n}}\right)$

⇒ 검정통계량 $T = \frac{\bar{X}-\mu_0}{S/\sqrt{n}} \sim t(n-1)$

→ 모분산 모르는데 $\bar{X}$ 정규분포 아닐 때 ---> 비모수적 분석(접근)

⇒ Bootstrapping : Bootstrap sample (원래의 표본에서 복원추출로 얻은 임의 표본)로 표본 분포 추정